

Explicación detallada de LightGBM optimizado con Optuna y de la trayectoria Monte Carlo del oro

Alejandro Ramirez

Leidy Paola Patiño

15 de junio de 2026

1. Propósito

Este documento explica de forma detallada el modelo final utilizado en el proyecto: **LightGBM optimizado con Optuna**. También se muestra cómo se construye una trayectoria Monte Carlo desde el primer día simulado hasta el valor final. La idea es dejar claro qué hace el modelo, qué variables usa, cómo funcionan los árboles, qué optimiza Optuna y por qué la simulación entregó los valores observados.

2. Qué es LightGBM

LightGBM significa *Light Gradient Boosting Machine*. Es una librería de aprendizaje automático para construir modelos predictivos basados en árboles de decisión y *gradient boosting*. Es ampliamente usada en datos tabulares, predicción financiera, riesgo, precios, demanda, clasificación y regresión.

En este trabajo LightGBM se usó para resolver una tarea de regresión: estimar el log-retorno del precio del oro del siguiente día hábil. No se predijo directamente el precio, sino el retorno logarítmico:

$$r_{t+1} = \ln \left(\frac{P_{t+1}}{P_t} \right), \quad (1)$$

donde P_t es el precio del oro en el día actual y P_{t+1} el precio del siguiente día hábil.

Luego, el precio se reconstruyó con:

$$\hat{P}_{t+1} = P_t e^{\hat{r}_{t+1}}. \quad (2)$$

Esta formulación es útil porque los retornos suelen ser más estables que los precios en nivel. Además, evita que el modelo aprenda directamente una tendencia de precio sin entender los cambios relativos.

3. Cómo funcionan los árboles de decisión

Un árbol de decisión divide los datos mediante reglas. Cada regla pregunta si una variable cumple una condición:

$$x_j \leq c, \quad (3)$$

donde x_j es una variable explicativa y c es un punto de corte.

Por ejemplo, una rama puede preguntar:

$$\text{volatilidad_oro_5} \leq c_1. \quad (4)$$

Si la respuesta es sí, la observación va a la rama izquierda; si no, va a la rama derecha. Más adelante el árbol puede preguntar por otra variable, por ejemplo:

$$\text{retorno_plata_5} \leq c_2. \quad (5)$$

Al final de cada camino hay una hoja. Esa hoja contiene un valor numérico que se suma a la predicción del retorno. En un modelo de boosting no hay un solo árbol, sino muchos árboles pequeños que se suman entre sí.

4. Cómo funciona el Gradient Boosting

LightGBM construye árboles de forma secuencial. Cada árbol nuevo intenta corregir los errores de los árboles anteriores. La predicción final del retorno se puede expresar así:

$$\hat{r}_{t+1} = F_M(X_t) = F_0(X_t) + \eta \sum_{m=1}^M f_m(X_t), \quad (6)$$

donde:

- X_t es el vector de variables disponibles en el día t .
- F_0 es una predicción inicial.
- f_m es el árbol número m .
- M es el número de árboles.
- η es el *learning rate* o tasa de aprendizaje.

La lógica es:

1. El modelo empieza con una predicción inicial.
2. Calcula cuánto se equivocó.
3. Entrena un árbol para corregir ese error.
4. Agrega ese árbol con peso pequeño.
5. Repite el proceso muchas veces.

LightGBM usa crecimiento por hojas, conocido como *leaf-wise growth*. Esto quiere decir que no divide todos los niveles del árbol al mismo tiempo, sino que busca la hoja donde más puede reducir el error. Esto suele mejorar la precisión, pero por eso se controlan hiperparámetros como `num_leaves` y `min_child_samples`.

5. Qué es Optuna

Optuna es una librería de optimización automática de hiperparámetros. Un hiperparámetro es una decisión de diseño del modelo, por ejemplo cuántos árboles usar, qué tasa de aprendizaje usar o cuántas hojas puede tener cada árbol.

Optuna hizo lo siguiente:

1. Propuso una combinación de hiperparámetros.
2. Entrenó LightGBM con esa combinación.
3. Midió el error usando validación temporal.
4. Guardó el RMSE promedio.
5. Propuso una nueva combinación, aprendiendo de las anteriores.

El objetivo matemático fue minimizar el error RMSE promedio en validación temporal:

$$\min_{\theta} RMSE_{CV}(\theta), \quad (7)$$

donde θ representa los hiperparámetros.

La configuración ganadora fue:

Cuadro 1: Hiperparámetros finales de LightGBM encontrados por Optuna.		
Hiperparámetro	Valor	Interpretación
<code>n_estimators</code>	400	Número de árboles construidos por el modelo.
<code>learning_rate</code>	0.0174355	Peso de cada árbol nuevo. Un valor bajo hace que el aprendizaje sea gradual.
<code>num_leaves</code>	38	Número máximo de hojas por árbol. Controla la complejidad de las reglas.
<code>subsample</code>	0.810038	Proporción de observaciones usadas en cada árbol.
<code>colsample_bytree</code>	0.730510	Proporción de variables usadas por árbol.
<code>min_child_samples</code>	23	Mínimo de observaciones necesarias en una hoja.

6. Todas las variables usadas por el modelo

El modelo final usó 76 variables. La Tabla 2 las agrupa por tipo y explica qué información aportan.

Cuadro 2: Variables usadas por LightGBM.

Variable	Significado
precio_oro	Precio actual del oro en USD/oz.
precio_plata	Precio actual de la plata en USD/oz.
ni_precio_recursos	Precio de oro usado para recursos minerales en reportes NI 43-101.
ni_precio_reservas	Precio de oro usado para reservas minerales en reportes NI 43-101.
cpi_us	Índice de precios al consumidor de Estados Unidos disponible.
fed_funds	Tasa de fondos federales disponible.
sp500	Nivel del índice S&P 500 disponible.
retorno_oro_1	Retorno porcentual del oro a 1 día.
retorno_oro_5	Retorno porcentual del oro a 5 días.
retorno_oro_10	Retorno porcentual del oro a 10 días.
diferencia_oro_1	Diferencia del precio del oro frente al día anterior.
diferencia_oro_5	Diferencia del precio del oro frente a 5 días atrás.
diferencia_oro_10	Diferencia del precio del oro frente a 10 días atrás.
precio_oro_lag_1	Precio del oro con rezago de 1 día.
precio_oro_lag_2	Precio del oro con rezago de 2 días.
precio_oro_lag_3	Precio del oro con rezago de 3 días.
precio_oro_lag_5	Precio del oro con rezago de 5 días.
precio_oro_lag_10	Precio del oro con rezago de 10 días.
precio_oro_lag_20	Precio del oro con rezago de 20 días.
ma_oro_3	Media móvil simple del oro a 3 días.
ema_oro_3	Media móvil exponencial del oro a 3 días.
volatilidad_oro_3	Volatilidad móvil del oro a 3 días.
ma_oro_5	Media móvil simple del oro a 5 días.
ema_oro_5	Media móvil exponencial del oro a 5 días.
volatilidad_oro_5	Volatilidad móvil del oro a 5 días.
ma_oro_10	Media móvil simple del oro a 10 días.
ema_oro_10	Media móvil exponencial del oro a 10 días.
volatilidad_oro_10	Volatilidad móvil del oro a 10 días.
ma_oro_20	Media móvil simple del oro a 20 días.
ema_oro_20	Media móvil exponencial del oro a 20 días.
volatilidad_oro_20	Volatilidad móvil del oro a 20 días.
ma_oro_30	Media móvil simple del oro a 30 días.
ema_oro_30	Media móvil exponencial del oro a 30 días.
volatilidad_oro_30	Volatilidad móvil del oro a 30 días.
ratio_oro_plata	Relación entre precio del oro y precio de la plata.
retorno_plata_1	Retorno porcentual de la plata a 1 día.
retorno_plata_5	Retorno porcentual de la plata a 5 días.
diferencia_plata_1	Diferencia diaria del precio de la plata.
precio_plata_lag_1	Precio de la plata con rezago de 1 día.

Variable	Significado
precio_plata_lag_2	Precio de la plata con rezago de 2 días.
precio_plata_lag_5	Precio de la plata con rezago de 5 días.
precio_plata_lag_10	Precio de la plata con rezago de 10 días.
ma_plata_5	Media móvil simple de la plata a 5 días.
volatilidad_plata_5	Volatilidad móvil de la plata a 5 días.
ma_plata_10	Media móvil simple de la plata a 10 días.
volatilidad_plata_10	Volatilidad móvil de la plata a 10 días.
ma_plata_20	Media móvil simple de la plata a 20 días.
volatilidad_plata_20	Volatilidad móvil de la plata a 20 días.
cpi_us_chg_1	Cambio porcentual de CPI a 1 periodo.
cpi_us_chg_5	Cambio porcentual de CPI a 5 periodos.
cpi_us_lag_1	CPI rezagado 1 periodo.
cpi_us_ma_5	Media móvil de CPI a 5 periodos.
cpi_us_ma_20	Media móvil de CPI a 20 periodos.
fed_funds_chg_1	Cambio porcentual de fed funds a 1 periodo.
fed_funds_chg_5	Cambio porcentual de fed funds a 5 periodos.
fed_funds_lag_1	Fed funds rezagado 1 periodo.
fed_funds_ma_5	Media móvil de fed funds a 5 periodos.
fed_funds_ma_20	Media móvil de fed funds a 20 periodos.
sp500_chg_1	Cambio porcentual del S&P 500 a 1 día.
sp500_chg_5	Cambio porcentual del S&P 500 a 5 días.
sp500_lag_1	S&P 500 rezagado 1 día.
sp500_ma_5	Media móvil del S&P 500 a 5 días.
sp500_ma_20	Media móvil del S&P 500 a 20 días.
ni_gap_recursos_reserva	Diferencia entre precio NI de recursos y precio NI de reservas.
anio	Año calendario.
mes	Mes calendario.
trimestre	Trimestre calendario.
dia_mes	Día del mes.
dia_semana	Día de la semana.
semana_anio	Semana del año.
mes_inicio	Indicador de inicio de mes.
mes_fin	Indicador de fin de mes.
mes_sin	Componente seno del ciclo mensual.
mes_cos	Componente coseno del ciclo mensual.
dia_semana_sin	Componente seno del ciclo semanal.
dia_semana_cos	Componente coseno del ciclo semanal.

7. Variables más usadas en las decisiones de los árboles

Aunque el modelo recibió 76 variables, unas tuvieron más peso en las divisiones de los árboles. Las principales fueron:

Cuadro 3: Variables con mayor importancia en LightGBM.

Variable	Importancia
volatilidad_oro_5	619
retorno_plata_5	607
volatilidad_oro_3	606
retorno_oro_5	592
volatilidad_oro_10	584
sp500_chg_1	577
volatilidad_plata_10	562
diferencia_oro_5	518
volatilidad_oro_30	517
sp500_chg_5	516




Figura 1: Importancia de variables del modelo LightGBM seleccionado.

8. Por qué LightGBM fue el modelo final

El modelo final fue seleccionado porque tuvo el menor RMSE promedio en validación temporal. La comparación principal fue:

Cuadro 4: Comparación por validación temporal.

Modelo	MAE CV	RMSE CV	R^2 CV
LightGBM + Optuna	17.4113	22.5191	0.9669
LightGBM manual	18.1269	23.4337	0.9639
HistGradientBoosting	18.8968	24.3490	0.9633
CatBoost	19.0538	24.3956	0.9663
XGBoost	21.4520	27.7745	0.9575

Esto significa que XGBoost fue superado en esta versión mejorada, aunque había sido el mejor en el trabajo anterior.

9. Cómo se genera una trayectoria Monte Carlo

El modelo LightGBM entrega un retorno base para cada día futuro:

$$\hat{r}_t = f(X_t). \quad (8)$$

Luego la simulación Monte Carlo agrega un choque aleatorio:

$$r_t^{MC} = \hat{r}_t + \text{choque}_t. \quad (9)$$

Ese choque viene de la volatilidad histórica/residual y de la estructura aleatoria del escenario base. Por eso la simulación “botó” un valor distinto a la mediana: no usa solo el retorno esperado del modelo, sino que agrega incertidumbre.

Después se reemplaza el retorno simulado en la fórmula exponencial:

$$P_t^{MC} = P_{t-1}^{MC} e^{r_t^{MC}}. \quad (10)$$

La fórmula acumulada desde el inicio hasta cualquier fecha T es:

$$P_T^{MC} = P_0 \exp \left(\sum_{t=1}^T r_t^{MC} \right). \quad (11)$$

10. Ejemplo numérico paso a paso

La trayectoria inicia con el último precio histórico observado:

$$P_0 = 4719.285 \text{ USD/oz.} \quad (12)$$

10.1. Primer día simulado: 2026-04-09

El modelo LightGBM entregó un retorno base:

$$\hat{r}_1 = 0.001800. \quad (13)$$

La simulación Monte Carlo generó un choque negativo:

$$\text{choque}_1 = -0.018433. \quad (14)$$

Entonces el retorno simulado fue:

$$r_1^{MC} = 0.001800 - 0.018433 = -0.016633. \quad (15)$$

Se reemplaza en la fórmula:

$$P_1^{MC} = 4719.285 \times e^{-0.016633} = 4641.44 \text{ USD/oz.} \quad (16)$$

La simulación entregó un precio menor porque el choque aleatorio fue negativo y superó al retorno base positivo del modelo.

10.2. Segundo día simulado: 2026-04-10

Ahora el precio inicial ya no es 4719.285, sino el precio simulado anterior:

$$P_1^{MC} = 4641.44. \quad (17)$$

El retorno base fue nuevamente 0.001800 y el choque fue 0.000488:

$$r_2^{MC} = 0.001800 + 0.000488 = 0.002288. \quad (18)$$

Entonces:

$$P_2^{MC} = 4641.44 \times e^{0.002288} = 4652.07 \text{ USD/oz.} \quad (19)$$

10.3. Tercer día simulado: 2026-04-13

El retorno simulado fue:

$$r_3^{MC} = 0.001800 + 0.021479 = 0.023279. \quad (20)$$

Por tanto:

$$P_3^{MC} = 4652.07 \times e^{0.023279} = 4761.64 \text{ USD/oz.} \quad (21)$$

Aquí la trayectoria subió porque el choque fue fuerte y positivo.

10.4. Primeros pasos resumidos

Cuadro 5: Primeros valores de la trayectoria Monte Carlo.

Fecha	Retorno base	Choque	Retorno MC	Precio MC
2026-04-09	0.001800	-0.018433	-0.016633	4641.44
2026-04-10	0.001800	0.000488	0.002288	4652.07
2026-04-13	0.001800	0.021479	0.023279	4761.64
2026-04-14	0.001800	0.014592	0.016392	4840.34
2026-04-15	0.000951	0.012809	0.013761	4907.40

11. Cómo se llega al resultado final

La trayectoria tiene 2538 pasos, desde 2026-04-09 hasta 2035-12-31. En cada paso se repite exactamente el mismo procedimiento:

1. LightGBM calcula $\hat{r}_t$ usando las 76 variables disponibles o proyectadas.
2. Monte Carlo genera un choque choque_t .
3. Se calcula $r_t^{MC} = \hat{r}_t + \text{choque}_t$.
4. Se actualiza el precio con $P_t = P_{t-1}e^{r_t^{MC}}$.

Para no imprimir 2538 operaciones una por una, se usa la forma acumulada. La suma de todos los retornos simulados de la trayectoria fue:

$$\sum_{t=1}^{2538} r_t^{MC} = 0.735430. \quad (22)$$

Entonces el precio final se obtiene reemplazando en la fórmula acumulada:

$$P_{2538}^{MC} = 4719.285 \times e^{0.735430} = 9846.22 \text{ USD/oz.} \quad (23)$$

Ese es el valor final de la trayectoria individual en 2035-12-31. No es la mediana del escenario, sino una ruta posible. La mediana $P50$ del escenario base para esa fecha fue 5427.87 USD/oz, mientras que esta trayectoria terminó más arriba porque la suma acumulada de choques fue positiva.

11.1. Últimos pasos de la trayectoria

Cuadro 6: Últimos valores de la trayectoria Monte Carlo.

Fecha	Retorno base	Choque	Retorno MC	Precio MC
2035-12-25	-0.000050	-0.005057	-0.005107	9356.17
2035-12-26	-0.000050	-0.014985	-0.015035	9216.55
2035-12-27	-0.000050	0.003705	0.003655	9250.30
2035-12-28	0.001185	0.020016	0.021201	9448.51
2035-12-31	-0.000050	0.041281	0.041231	9846.22

12. Lectura de la gráfica

En la Figura 2, la línea roja es la trayectoria individual calculada con los pasos anteriores. La línea naranja es la mediana $P50$ del escenario base y la banda sombreada representa los percentiles $P10$ y $P90$.




Figura 2: Trayectoria individual generada con LightGBM + Optuna y Monte Carlo.

Si la línea roja sube por encima de la mediana, significa que los choques acumulados de esa ruta fueron más positivos que el caso central. Si se acerca al percentil 90, está en la parte alta de la distribución simulada. Si baja hacia el percentil 10, está en la parte baja.

13. Conclusión

LightGBM + Optuna funciona combinando árboles de decisión secuenciales con búsqueda automática de hiperparámetros. Los árboles deciden usando variables como volatilidad del oro, retornos de la plata, diferencias del oro y cambios del S&P 500. Optuna encontró una configuración que redujo el RMSE de validación temporal frente a XGBoost y otros modelos. Luego, la trayectoria Monte Carlo tomó los retornos base de LightGBM, agregó choques aleatorios y actualizó el precio día a día con la fórmula exponencial. Por eso cada valor de la trayectoria tiene una explicación: proviene de un retorno base del modelo más un choque de simulación, reemplazado en $P_t = P_{t-1}e^{r_t}$.